



教育经历

中国科学院大学 网络空间安全 硕博连读 (保研) GPA: 3.88/4 2022.09 – 至今
研究方向: 多模态、自然语言处理 | 学生工作: 宣传部部长
武汉大学 信息安全 本科 (优秀毕业生) GPA: 3.95/4 (2/147) 2018.09 – 2022.06

科研经历

产出论文10余篇, 独立第一作者发表论文5篇 (1篇CCF-A, 2篇CCF-B), 在投论文2篇 (ACL、IJCAI在投)。

博士研究课题: 多模态讽刺理解

2023.09 – 至今

Multi-View Incongruity Learning for Multimodal Sarcasm Detection

COLING 2025 (CCF-B)

- 问题: 现有模型倾向于学习数据中的虚假相关 (如过度依赖特定情感词), 导致泛化能力差。
- 贡献: 提出 MICL 框架, 从词元-图像块、实体-对象、情感三个互补视角学习图文不协调, 并设计全面的图文数据增强策略, 构建虚假相关测试集 SPMSD。该方法在提升检测精度的同时, 有效增强了模型鲁棒性。

Towards Generalized Multimodal Sarcasm Detection with Multi-View Learning

TASLP 2025 (CCF-B)

- 问题: 多视角融合存在冲突, 且模型复杂度高。
- 贡献: 提出 ConDi 框架, 引入最优传输对齐异构图文特征, 并设计基于冲突的证据融合机制处理视角分歧。在保持性能的同时, 核心参数减少近90%, 并在多个域外数据集上表现出卓越的泛化能力。

MuVaC: A Variational Causal Framework for Multimodal Sarcasm Understanding

WWW 2026 (CCF-A)

- 问题: 现有方法将讽刺检测与讽刺解释视为独立或并行的任务, 忽略了解释逻辑与检测判断的内在因果链。
- 贡献: 首次将多模态讽刺理解建模为变分因果推断问题。设计结构因果模型与变分下限进行优化, 让模型在生成解释的同时, 学习用于检测的因果特征, 实现讽刺认知链条的显式建模。在多个公开数据集上取得最优。

Orthogonal Expert Tuning for Holistic Multimodal Sarcasm Understanding

ACL 2026在投 (CCF-A)

- 问题: 多模态讽刺理解包含多个异构子任务 (如检测、解释、目标识别等), 共享参数训练时会导致特征纠缠, 细粒度任务会侵蚀基础感知能力。
- 贡献: 主导构建首个统一的五维度评测基准 DocMSU-PLUS, 将所有子任务转化为多项选择题, 首次实现单一指标评估。并提出 DOSE 框架, 通过双正交流专家结构解耦共享感知与私有执行, 从几何空间上阻断多任务间的梯度干扰, 在仅用1%训练数据的低资源场景下取得最优性能。

近期研究兴趣: 大模型后训练与奖励模型

- 已合作投稿2篇A类论文, 基于强化学习优化 RAG 系统的检索与推理策略, 有效解决开放域多跳问答中的检索坍塌与 Unfaithful Reasoning 难题。类似的, 我目前针对生成式奖励模型存在“结果-过程不一致性”缺陷开展研究, 即模型可能猜对了哪个回答更好, 但给出的理由却是胡说八道或细枝末节, 成果拟投稿 NeurIPS。

项目经历

十亿级社交平台恶意信息判别系统

2023.09-2024.12

- 背景与目标: 在十亿级真实社交平台语料上, 构建一套高效的恶意信息 (如讽刺性攻击、隐性仇恨言论) 自动判别系统, 以辅助平台进行内容审核与违规账号治理。
- 核心贡献: 将多模态讽刺理解研究与传统方法相结合, 解决了传统方法难以捕捉“说反话”等隐性恶意信息的难题。主导了算法从实验原型到可部署系统的迁移。优化了数据处理 pipeline, 使其能稳定处理每日新增的数千万条多模态数据。系统判别准确率达到90%以上, 相比原有基于规则的系统, 召回率预估提升超过25%。系统已累计处理超52亿条数据, 成功识别并标记近千个违规账号。基于本项目完成2项发明专利。

基于RAG与证据对齐的医保政策问答系统

2024.09-2025.03

- 背景与挑战: 构建一个基于大语言模型的医保政策智能问答系统, 核心难点在于医保政策问答要求答案100%严格依据文件原文, 传统RAG系统易产生自由发挥或推测, 无法满足法律效力要求。
- 核心贡献: 利用LLM将非结构化政策文本自动抽取为“条款-条件-值”三元组, 构建可精确检索的政策知识库, 解决表格类数据 (报销比例表) 的检索难题。引入审计模块, 通过规则+模型双重校验确保无新增内容。设计针对“严格依据证据”的奖励函数 (包括原文匹配度、引用正确性、无新增内容), 使用DPO进行优化, 使模型学会抑制自由发挥。系统在黑龙江某市试点, 已处理200+咨询, 人工评估准确率95%。

获奖情况

- “基于文心CV大模型的智慧城市视觉多任务识别大赛” 东部赛区二等奖 2022
- 中国科学院信息工程研究所“所长优秀奖”, 中国科学院大学“优秀学生” 2023、2024
- 武汉大学学业奖学金一二等奖、国家网络安全基地奖学金一等奖 2019、2020、2021

技能特长

- 编程语言与框架: Python, 熟悉torch、transformers等库的使用。
- 语言能力: CET-6 (545分), 日语 JLPT N2 (180/180 满分)。
- 核心优势: 深入理解多模态对齐机制 (基于多模态讽刺研究积累), 具备一定的大模型后训练实战能力。